UNIVERSIDADE
LUSÓFONA

Proposta Assistente Web de Conhecimento Empresarial com Modelos de Linguagem e RAG

AHMED AL-MAJMAIE
Projeto I | L.E.I. | 2026 / 27

www.ulusofona.pt

Índice

1. Descrição----------3
1.1. Ingestão e Vetorização de Dados (Backend) ----------3
1.2. Motor de Respostas Baseadas em Factos (IA)----------3
1.3. Gestão e Controlo de Acessos (Interface Web) ----------3
2. Objetivos ----------3
2.1. Centralizar e Otimizar a Recuperação de Informação ----------3
2.2. Eliminar Alucinações de IA (Zero-Hallucination)----------4
2.3. Garantir a Segurança e Segregação de Dados----------4
2.4. Assegurar Transparência e Auditoria Contínua----------4
2.5. Automatizar o Pipeline de Dados----------4
3. Planeamento e Metodologia----------4
4. Motivação da Proposta ----------5
4.1. Valor Operacional e de Negócio ----------6
4.2. Valor Tecnológico ----------6

1. Descrição

O presente projeto consiste no desenvolvimento de um Assistente Web corporativo baseado na arquitetura RAG (*Retrieval-Augmented Generation*). Trata-se de uma plataforma inteligente de pesquisa e interação documental, concebida para fornecer respostas exatas e contextuais a partir de repositórios de dados internos não estruturados (como manuais técnicos ou normas de procedimentos oficiais).

A arquitetura do sistema afasta-se da simples utilização de modelos de linguagem genéricos, estruturando-se em três módulos funcionais principais:

1.1. Ingestão e Vetorização de Dados (Backend)

Um motor de processamento automatizado que consome documentos internos oficiais (PDF, Word, HTML). O algoritmo extrai o texto, segmenta-o semanticamente (*chunking*) e converte a informação em representações matemáticas (*embeddings*), armazenando-as numa base de dados vetorial dedicada para criar um repositório de conhecimento fechado.

1.2. Motor de Respostas Baseadas em Factos (IA)

O núcleo lógico de recuperação de informação. Perante uma pergunta, o algoritmo pesquisa estritamente na base de dados vetorial. O Modelo de Linguagem (LLM) é instruído a gerar a resposta utilizando, em exclusivo, os blocos de texto recuperados, apresentando obrigatoriamente a citação e o atalho direto para a página do documento original.

1.3. Gestão e Controlo de Acessos (Interface Web)

Uma aplicação *frontend* (pesquisa e chat) complementada por um Painel de Administração. Este módulo gere a aprovação de novos conteúdos e implementa um modelo rigoroso de controlo de acessos por tipo de utilizador (RBAC), assegurando a segregação de informação por equipas/áreas (ex.: Recursos Humanos, Qualidade ou Suporte). Paralelamente, mantém um registo de auditoria relacional com o histórico de todas as consultas.

2. Objetivos

O projeto tem como finalidade principal conceber e implementar uma solução de *software* que resolva a ineficiência no acesso a documentação técnica corporativa, assegurando o rigor e a segurança da informação. Para tal, definem-se os seguintes objetivos técnicos e de engenharia:

2.1. Centralizar e Otimizar a Recuperação de Informação

Resolver o problema da dispersão documental, substituindo a pesquisa manual em ficheiros extensos por um motor de busca semântico que entrega respostas exatas e imediatas, reduzindo drasticamente o tempo de resolução de problemas operacionais.

2.2. Eliminar Alucinações de IA (Zero-Hallucination)

Desenvolver um sistema de geração de respostas estritamente ancorado nos dados internos (*grounding*), garantindo que a Inteligência Artificial não inventa informação e comprova sempre a veracidade dos dados através de citações rastreáveis.

2.3. Garantir a Segurança e Segregação de Dados

Implementar políticas robustas de controlo de acessos (RBAC) para assegurar que diferentes utilizadores acedem apenas à documentação da sua área de permissão, resolvendo o risco de fuga de informação interna sensível.

2.4. Assegurar Transparência e Auditoria Contínua

Integrar um sistema de *logging* que registe de forma imutável a identidade do utilizador, a pergunta formulada, as fontes acedidas e a resposta gerada, fornecendo à administração corporativa um mecanismo total de monitorização e auditoria.

2.5. Automatizar o Pipeline de Dados

Desenvolver e afinar os algoritmos de extração, limpeza e vetorização de texto, permitindo que a inserção de novos manuais ou normas no sistema seja um processo ágil, escalável e de fácil manutenção para a empresa.

3. Planeamento e Metodologia

O ciclo de desenvolvimento do sistema adotará uma abordagem iterativa e incremental, dividida estrategicamente entre os dois semestres letivos. O Projeto I concentra-se na especificação rigorosa de requisitos, no desenho da arquitetura de *software* e na construção de um Produto Mínimo Viável (MVP), enquanto o Projeto II absorve a implementação estrutural, a otimização do Modelo de Linguagem e os testes em ambiente real.

Fase de Desenvolvimento	Atividades Técnicas e Foco	Marco de entrega (*Milestone*)
Engenharia de Requisitos	Elicitação de requisitos funcionais e não funcionais, identificação de perfis de utilizador, elaboração de casos de uso com critérios de aceitação e matriz de rastreabilidade.	Relatório Preliminar de Engenharia de Requisitos (Prazo: 9 de novembro de 2026).

Fase de Desenvolvimento	Atividades Técnicas e Foco	Marco de entrega (*Milestone*)
Arquitetura e Protótipo (MVP)	Desenho dos diagramas de arquitetura, fluxo de dados e interfaces. Programação de um protótipo funcional inicial capaz de demonstrar os fluxos prioritários de pesquisa RAG com dados de teste para validação de risco técnico.	Relatório de Engenharia de Software (Prazo: 16 de dezembro de 2026).
Projeto II	**Implementação**	**2ºSemestre**
Implementação do Pipeline de Dados e IA	Construção do *backend* de produção. Implementação dos algoritmos de extração, limpeza e *chunking* de PDFs reais. Integração robusta via API com o Modelo de Linguagem (LLM) para garantir o bloqueio de "alucinações" em contexto empresarial.	2º Semestre (A definir).
Interface, Segurança e Validação Operacional	Fecho do desenvolvimento da aplicação web e do Painel de Administração. Implementação das políticas de permissões (RBAC) e do sistema de auditoria relacional (*logs*). Condução dos testes de validação com utilizadores operacionais no terreno.	Defesa Final de Projeto II (2º Semestre).

4. Motivação da Proposta

Em ambientes operacionais e de suporte técnico (como nas montagens audiovisuais ou operações de *e-commerce*), o conhecimento técnico encontra-se frequentemente fragmentado por dezenas de documentos extensos e não estruturados, como manuais de equipamentos, normas de procedimentos e *datasheets*. A necessidade de aceder a configurações críticas sob pressão de tempo torna o processo de pesquisa manual não apenas ineficiente, mas também propício a falhas humanas que podem comprometer operações inteiras.

Embora a Inteligência Artificial Generativa (através de LLMs) ofereça um enorme potencial para a extração de conhecimento, a sua adoção direta por parte das empresas esbarra em dois obstáculos

críticos: o risco de fuga de dados sensíveis para modelos públicos e a ocorrência de "alucinações" (geração de respostas incorretas ou inventadas com excesso de confiança).

É neste contexto que a resolução deste problema se torna fundamental. A importância deste projeto reside na capacidade de transpor a fronteira entre a IA genérica e a Engenharia de Software aplicada, utilizando a arquitetura RAG (*Retrieval-Augmented Generation*) para criar uma barreira de segurança e precisão.

4.1. Valor Operacional e de Negócio

Cria-se uma ferramenta que reduz drasticamente o tempo despendido pelos técnicos na procura de informação (de minutos de leitura para segundos de resposta), mitigando o erro humano através do fornecimento da citação exata e documentada. Adicionalmente, acelera a curva de aprendizagem de novos colaboradores.

4.2. Valor Tecnológico

Desenvolve-se uma infraestrutura de conhecimento fechada, soberana e auditável, provando que é possível integrar o poder de raciocínio lógico dos Modelos de Linguagem na realidade empresarial moderna sem comprometer a privacidade ou a governança dos dados internos.